Hledání architektur neuronových sítí v úloze mapování produktů



Repozitář

Autor: Adam Vrba | Rok obhajoby: 2025

Úloha mapování produktů

- Cílem mapování produktů je porovnat dva produkty z různých e-shopů a určit, zda se jedná o shodné produkty.
- K určení shodnosti produktů použijeme název, popisek, cena, specifikace a obrázek produktu.

Hledání architektur neuronových sítí

- Hledání architektur neuronových sítí je optimalizační algoritmus, jehož cílem je objevit nejvýkonnější model neuronové sítě určením optimální architektury včetně hyperparametrů sítě.
- V práci jsme použili následující strategie pro nalezení optimální architektury.
 - a. Random search: Šířka i hloubka vrstev v architektuře jsou náhodně zvoleny.
 - b. NEAT: Evoluční algoritmus, který vyvijí váhy i topologii sítě zároveň.
 - c. HyperNEAT: Pomocí fixních souřadnic (substrát) a CPPN sítě vytváří mezi předem určených bodů hrany, ze kterých je určena výsledná architektura.
 - d. ES-HyperNEAT: Rozšíření HyperNEAT, umožňuje flexibilnější geneorvání struktur síťe pomocí vyvíjení substrátu.
 - e. CoDeepNEAT: Rozšíření NEAT algoritmu, populace se skládá z modulů a blueprintů, obě struktury se vyvijí zároveň. Modul je mělká neuronová síť. Blueprint pak popisuje jak jednotlivé moduly spojit do sebe, čímž se vytvoří výsledná architektura neuronové sítě.

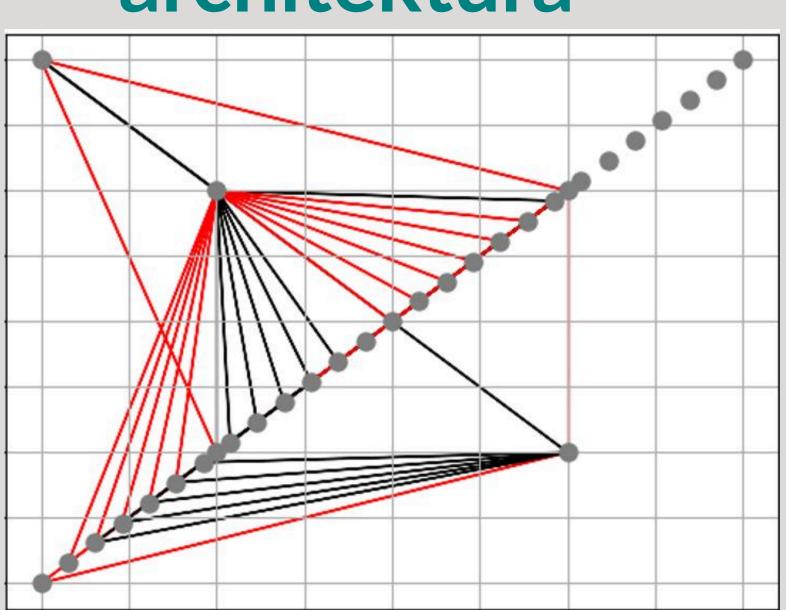
Cíl práce

- Cílem práce bylo provést experimenty zaměřené na hledání architektur neuronových sítí v úloze mapování produktů a porovnat výkon architektur, které byly nalezené pomocí strategií s ručně navrženými modely.
- Všechny neuronové sítě jsme natrénovali na ProMapCz, ProMapEn, Amazon-Walmart a Amazon-Google datasetech, které obsahují data určené pro úlohu mapování produktů.
- Jmenované datasety obsahují například obrázky, název produktu, krátký dlouhý popisek a specifikaci.
- Předzpracování obrázků bylo provedeno pomocí percepční hashovací metody, která obrázky převedla na číselné hodnoty. Mezi párem produktů se spočítala Hammingova vzdálenost a celková podobnost mezi párem produktu se určil jako součet všech párů obrázků, které měly shodu vyšší než 90 %.
- Veškerý text byl lemmatizován pomocí morfologického analyzátoru Majka a
 předzpracovaný text byl převeden pomocí TF-IDF na číselný vektor, ze kterého se
 určila kosínová vzdálenost textu, krátkých a dlouhých popisků. Dále byly
 detekovány klíčová slova jako je například ID, značka produktu, nebo také číselné
 hodnoty, a případně jejich jednotky.

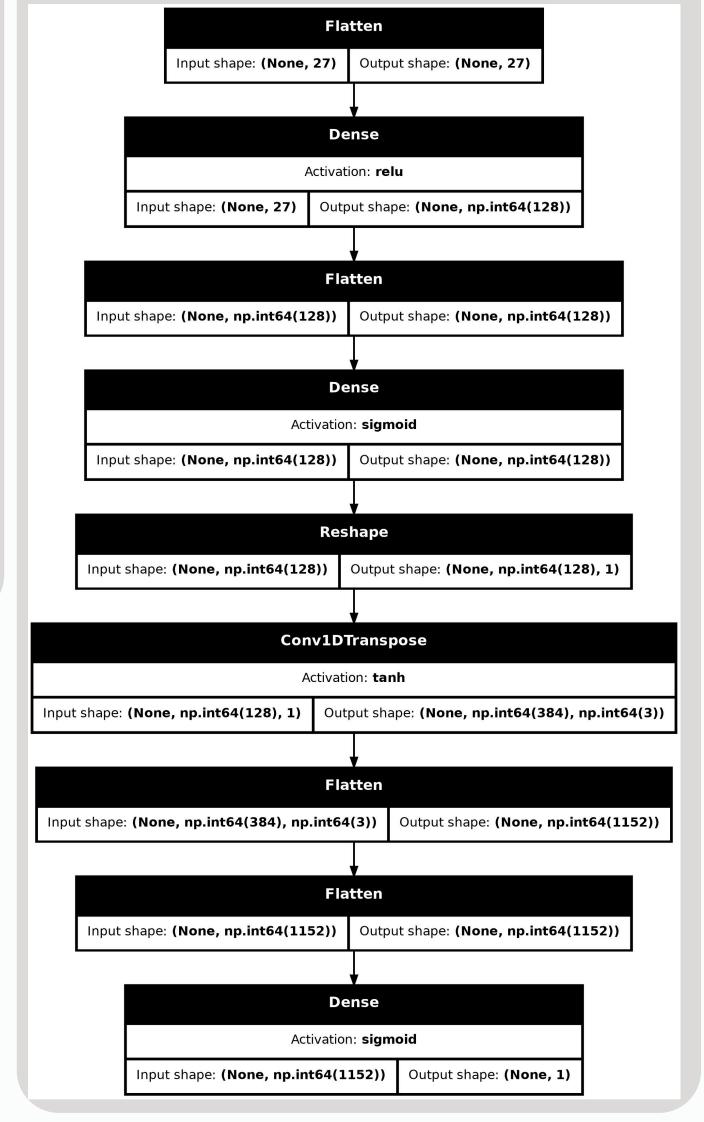
Výsledky experimentu

Strategies	Trénovací dataset	F1 skóre	Accuracy	Precision	Recall
Ruční návrh	Amazon-Google	99%	99%	100%	98%
Random search	Amazon-Google	98%	99%	99%	98%
NEAT	Amazon-Google	99%	99%	100%	98%
HyperNEAT	Amazon-Google	94%	95%	98%	95%
ES-HyperNEAT	Amazon-Google	97%	98%	98%	95%
CoDeepNEAT	Amazon-Google	98%	99%	98%	98%
Ruční návrh	Amazon-Walmart	92%	94%	91%	93%
Random search	Amazon-Walmart	89%	92%	93%	85%
NEAT	Amazon-Walmart	92%	94%	90%	94%
HyperNEAT	Amazon-Walmart	77%	82%	70%	86%
ES-HyperNEAT	Amazon-Walmart	86%	89%	80%	92%
CoDeepNEAT	Amazon-Walmart	91%	93%	92%	89%
Ruční návrh	ProMapCz	75%	84%	79%	71%
Random search	ProMapCz	74%	84%	80%	69%
NEAT	ProMapCz	75%	82%	68%	84%
HyperNEAT	ProMapCz	59%	65%	48%	78%
ES-HyperNEAT	ProMapCz	70%	76%	60%	85%
CoDeepNEAT	ProMapCz	76%	83%	70%	83%
Ruční návrh	ProMapEn	57%	76%	69%	49%
Random search	ProMapEn	45%	75%	78%	32%
NEAT	ProMapEn	68%	76%	59%	81%
HyperNEAT	ProMapEn	61%	65%	48%	85%
ES-HyperNEAT	ProMapEn	64%	73%	57%	74%
CoDeepNEAT	ProMapEn	49%	72%	59%	43%

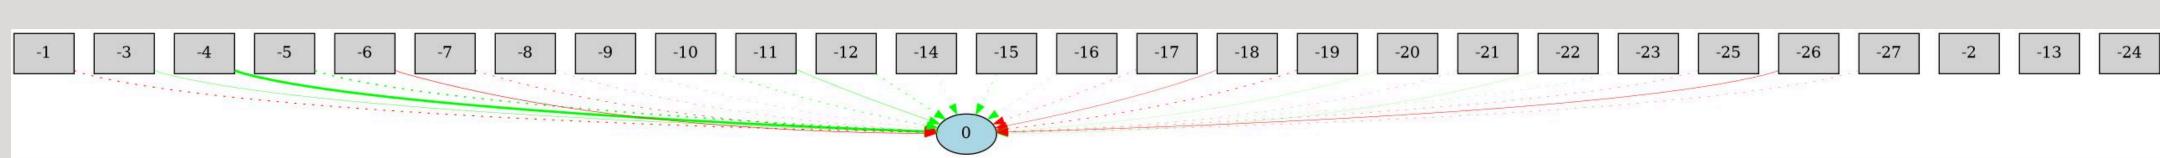
ES-HyperNEAT architektura



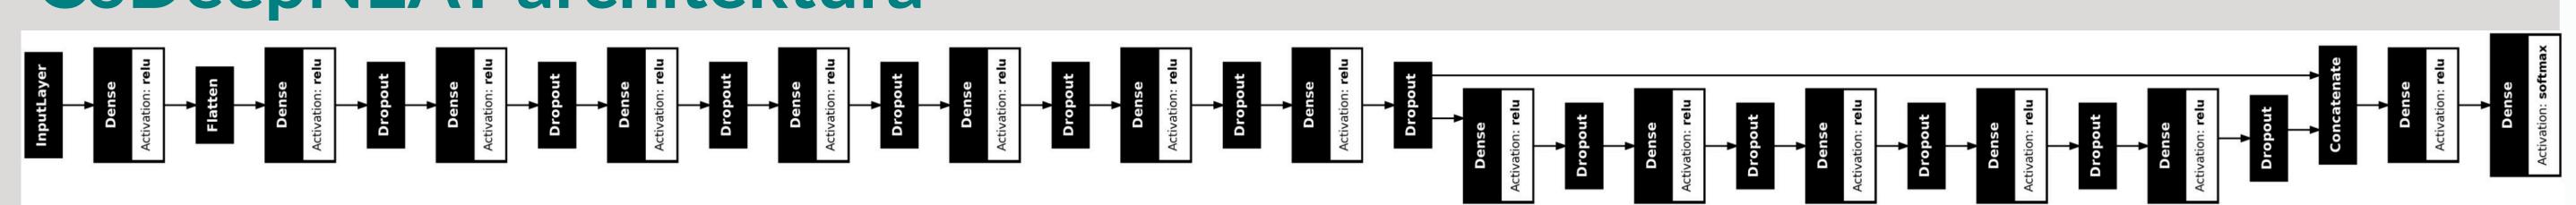
Random search architektura



NEAT architektura



CoDeepNEAT architektura



Email: vrbaada@gmail.com Vedoucí práce: RNDr. Kateřina Macková